

《数据挖掘实践》课程考核报告

题目：房屋数据多元线性回归模型

学院： 信息科学与技术学院

专业： 数据科学与大数据技术

班级： F230161

姓名： 郭子旭

学号： F23016121

目录

1 爬虫设计 **4**

1.1 数据来源 4

1.2 架构设计 4

1.2.1 列表页遍历 4

1.2.2 详情页并行采集 4

1.2.3 NUXT 数据解析 5

1.2.4 HTML 正则回退 5

1.3 反爬对抗 6

1.4 断点续抓 6

1.5 数据字段 6

1.6 输出 6

2 数据概况 **7**

2.1 数据规模 7

2.2 核心变量分布 7

2.3 首付与月供 8

2.4 地理特征 8

2.5 数据质量 8

3 数据处理 **9**

3.1 地理信息增强 9

3.2 特征提取 10

3.2.1 户型拆分 10

3.2.2 楼层等级 10

3.2.3 建造年代 10

3.2.4 衍生特征 10

3.3 VIF 多重共线性诊断 10

3.4 互信息特征选择 11

3.5 OLS 统计推断 11

3.6 异常值检测 12

3.7 One-Hot 编码 12

3.8 特征相关性 13

4 数据分析 **13**

4.1 房价分布 13

4.2 户型分析 13

4.3 地理位置与房价 14

4.4 房龄与房价 15

4.5 商圈对比 15
4.6 特征相关性分析 16

5 房价预测模型 16
5.1 特征工程 16
5.2 数据划分 17
5.3 模型选择 17
5.4 超参数调优 17
5.5 模型评估 17
5.6 交叉验证稳定性 18
5.7 房价高低二分类 18
5.8 特征重要性 19

6 可视化分析 20
6.1 总价分布 20
6.2 距离与房价关系 20
6.3 户型结构 21
6.4 综合特征重要性 21
6.5 装修等级与房价 22
6.6 建造年代与房价 22

7 AI 智能体扩展 23
7.1 设计目标与架构 23
7.2 ReAct 推理循环 24
7.2.1 流式输出架构 24
7.2.2 终止条件 24
7.3 工具系统 24
7.3.1 SESSION 缓存机制 24
7.3.2 JSON Schema 注册 25
7.4 Gradio 聊天界面 25
7.5 参数化爬虫 26
7.6 缓存与持久化机制 26
7.7 报告自动生成 26

8 数据挖掘 Skill 27
8.1 Skill 设计理念 27
8.2 核心工作流 27
8.2.1 环境初始化 27
8.2.2 数据理解 27
8.2.3 迭代分析 28

8.3 反爬专项指南 28
8.4 建模方法论 28
8.5 与 homework 和 Agent 的关系 28

9 结论与展望 **29**
9.1 核心发现 29
9.2 不足与改进方向 29
9.3 应用展望 30

1 爬虫设计

1.1 数据来源

数据采集自安居客（anjuke.com）上海曹路板块二手房房源页面。曹路板块位于上海市浦东新区东北部，毗邻上海杉达学院，是近年来浦东发展较快的居住板块之一。采集范围覆盖曹路及周边区域，以杉达学院为中心半径 10km 内的二手房源。

安居客作为国内领先的房产信息平台，其房源详情页采用 NUXT.js 服务端渲染架构，页面加载时将房源的结构化数据注入 `window.__NUXT__` 全局变量。这一架构特点为数据采集提供了极大便利——相比从 DOM 树逐字段解析 HTML，直接读取 `__NUXT__` 可获得一份完整、规范的 JSON 对象，避免了 HTML 标签不规则导致的解析错误。

1.2 架构设计

爬虫基于 DrissionPage 的 ChromiumPage 同步 API 实现，采用浏览器自动化方案。选择浏览器自动化而非 HTTP 请求直连的原因在于安居客的列表页和详情页均依赖 JavaScript 渲染——纯 HTTP 请求无法获取完整的 DOM 结构和 `window.__NUXT__` 数据。

1.2.1 列表页遍历

爬虫遍历曹路板块二手房列表页（目标 20 页，每页约 60 条）。对每个列表页：

1. 定位 class 为 `.property` 的房源卡片元素。
2. 从每个卡片提取三个基础字段:总价（`.property-price-total`）、单价（`.property-price-average`）小区名称（`.property-content-info-comm-name`）和详情链接（`<a>` 标签的 href）。
3. 验证码守卫：每次翻页后检查 URL 是否包含 `captcha`、`antibot`、`verifycode` 等关键字，拦截则循环等待用户手动通过。

1.2.2 详情页并行采集

列表页仅包含 4 个字段,剩余的 27 个字段需要从详情页获取。为提高效率,采用 `ThreadPoolExecutor(max_workers=2)` 并行抓取详情页：

- **独立标签页**：每个 worker 通过 `page.new_tab()` 创建独立标签页，避免并行请求间的状态污染。完成后关闭标签页释放资源。
- **线程安全写入**：所有 worker 通过 `csv_lock = threading.Lock()` 互斥写入 CSV 文件，防止数据交错。
- **去重过滤**：已抓取的详情链接存储在 `crawled_urls` 集合中，并行执行前过滤 pending 列表。

1.2.3 NUXT 数据解析

详情页的核心解析逻辑是调用 `page.run_js('return window.__NUXT__')`，直接获取页面底层的 Vuex Store 数据。`__NUXT__` 的数据结构如下：

```
__NUXT__ = {
  data: [{
    viewData: {
      property: {
        attribute: {      // 房源属性
          room_num, hall_num, toilet_num,      // 户型
          area_num,                            // 建筑面积
          floor_level, total_floor,            // 楼层
          orient,                              // 朝向
          house_age,                           // 建造年代
          fitment_name,                        // 装修情况
          right_type, use_type, right_age,     // 产权
          has_lift,                            // 电梯(0/1)
          budget: { first_pay_price, monthly_payment }  // 预算
        },
        tags: [...],                           // 房源标签
        government_verification: [{desc}]      // 核验编码
      },
      community: {       // 小区属性
        area_name, block_name, address,        // 区域
        lat, lng,                              // 经纬度
        green_rate, property_fee, households   // 小区信息
      },
      broker:             // 中介信息
        [{ company_name, store_name, name }]
    }
  }]
}
```

按此结构逐字段映射后，可一次性提取 31 个字段中的 27 个详情字段。其中 broker 可能是数组或字典，需要做防御性类型检查。

1.2.4 HTML 正则回退

部分小区信息（绿化率、物业费用、小区户数）在 `__NUXT__` 中可能缺失。作为回退方案，爬虫将页面滚动至底部（触发懒加载）后，通过正则表达式从原始 HTML 中匹配：

- **绿化率**：/绿化率 [^d]{0,20}(\d+\.?\d*%)/
- **物业费用**：/物业费用 [^d]*(\d+\.\d+[^<\n]{0,30})/
- **小区户数**：/小区户数 [^d]*(\d+)\s* 户/

正则匹配严格限制在 HTML 文本节点内（不使用 re.S），避免跨标签交叉匹配。

1.3 反爬对抗

安居客的反爬机制相对温和，但仍需处理以下问题：

1. **验证码拦截**：列表页或详情页出现验证码时，进入等待循环（每次 5 秒检查 URL，最多 60 次）。验证码弹出时暂停抓取，用户手动通过后自动恢复。
2. **请求间隔**：列表页翻页间隔 2–3 秒，详情页抓取间隔 2 秒，避免请求频率触发反爬阈值。
3. **第三方站点过滤**：自动跳转至 58 同城或新房频道的链接视为非安居客房源，直接跳过。
4. **HTML 污染清理**：部分字段（尤其是' 核心卖点'）可能混入 HTML 标签，通过正则 /<[^>]+>/g 移除标签符号，并将长度控制在 200 字符以内。

1.4 断点续抓

爬虫具备完整的断点续抓能力：

1. 启动时读取已有 CSV 文件，将所有详情链接加载到 crawled_urls 集合。
2. 根据已抓取数量估算当前页码：start_page = max(1, len(crawled_urls) // 60)。
3. 写入模式自动选择：有历史记录时用 'a'（追加），无历史记录时用 'w'（覆盖写入表头）。
4. 每页抓取时过滤 pending 列表，只抓取未抓取的 URL。

1.5 数据字段

共采集 31 个原始字段，涵盖房源属性、小区属性、交易信息三大类：

- **房源属性（11 个）**：房屋户型、建筑面积、所在楼层、总楼层、房屋朝向、建造年代、装修情况、配备电梯、核心卖点、房源标签、房源核验编码。
- **交易信息（5 个）**：总价、单价、首付、月供、产权性质、产权年限。
- **小区属性（8 个）**：小区名称、所属区域、所属商圈、小区地址、绿化率、物业费用、小区户数、经纬度。
- **中介信息（3 个）**：发布公司、所属门店、发布经纪人。

1.6 输出

原始数据输出为 anjuke_detail.csv，共 959 条有效记录，每条含 31 个字段。CSV 采用 utf-8-sig 编码，兼容 Excel 直接打开中文不乱码。

2　数据概况

2.1　数据规模

经爬虫采集和地理增强后，最终数据集包含 959 条房源记录、36 个字段。其中数值型字段 22 个，文本型字段 14 个。房源分布于 187 个独立小区，平均每个小区约 5.1 条记录。

表 1: 数据概况

指标	数值
有效房源记录数	959
原始字段数	31
增强后字段数	36
数值型字段	22
文本型字段	14
小区数	187

2.2　核心变量分布

房价分布：总价范围 78–3180 万元，均值 231 万元，中位数 202 万元，呈右偏分布（偏度系数约 1.8）。单价范围 15117–89762 元/平方米，均值 27125 元/平方米。约 62% 的房源集中在 150–300 万元区间。

建筑面积：范围 30–551 平方米，均值 82.6 平方米，中位数 79.1 平方米。以 60–100m² 的中小户型为主，反映曹路板块刚需定位。

楼层分布：总楼层均值 12.5 层，标准差 6.8 层。从中位值来看，曹路板块以 8–18 层的小高层和高层住宅为主。

时间跨度：建造年代范围 1980–2025 年，平均房龄约 15 年。各年代段分布如下：

表 2: 房龄分布

建造年代	数量	占比
2000 年以前（老旧房）	89	9.3%
2000–2009 年（老房）	287	29.9%
2010–2019 年（次新房）	408	42.5%
2020 年以后（新房）	175	18.3%

次新房（2010–2019 年建成）占据最大比例，说明曹路板块在过去十年经历了密集的房地产开发。

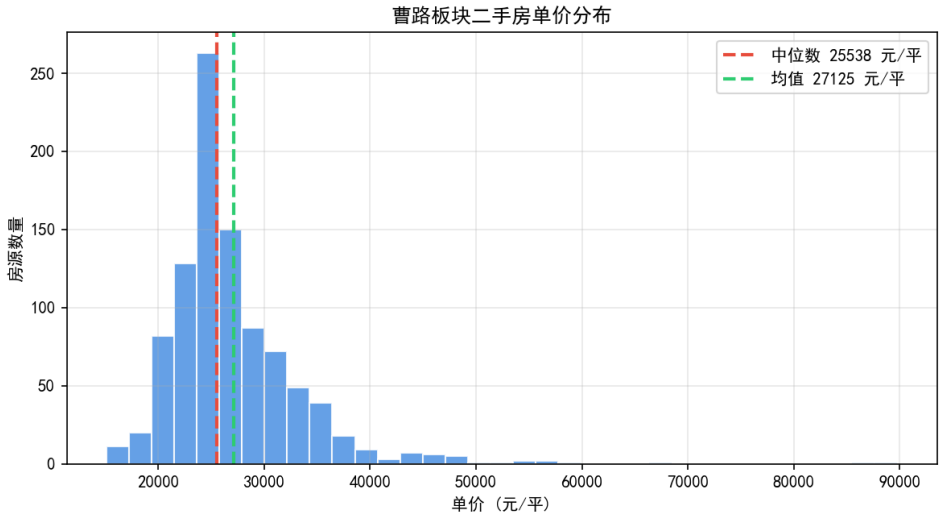


图 1: 曹路板块二手房单价分布

单价分布与总价类似呈右偏特征，主体集中在 22000–32000 元/m² 区间。

表 3: 楼层高度分布

总楼层区间	数量	占比
1–6 层（多层）	182	19.0%
7–12 层（小高层）	328	34.2%
13–18 层（高层）	291	30.3%
19 层以上（超高层）	158	16.5%

2.3　首付与月供

首付区间 23–1620 万元，均值 74 万元，中位数 61 万元。月供区间 2315–61200 元，均值 8500 元，中位数 7200 元。按上海 30% 首付比例估算，曹路板块购房门槛约 60 万元首付、月供 7000 元左右。

2.4　地理特征

通过高德地图 API 对每个小区进行 POI（兴趣点）增强，获取以下地理特征：

- **距参考点距离**：以杉达学院为参考点，房源距离范围 0.41–9.38 km，均值 2.88 km。81.2% 的房源位于参考点 4km 范围内。
- **地铁站数量**：1.5km 半径内地铁站数量 0–14 个，均值 5.15 个。曹路板块 9 号线沿线的房源地铁配套尤为密集。
- **医院数量**：3km 半径内医院数量 3–23 个，均值 7.92 个。
- **商场数量**：2km 半径内商场数量 0–12 个，均值 4.17 个。

2.5　数据质量

数据集整体质量良好。具体字段缺失情况如下：

表 4: 地理特征描述统计

特征	均值	标准差	最小值	中位数	最大值
距参考点 (km)	2.88	1.19	0.41	3.13	9.38
地铁站数量	5.15	4.32	0.00	6.00	14.00
医院数量	7.92	2.31	3.00	8.00	23.00
商场数量	4.17	3.02	0.00	4.00	12.00

- **绿化率**：缺失率约 88%。该字段在安居客详情页中并非必填项，大量房源未录入。在后续特征工程中予以移除。
- **物业费用/小区户数**：缺失率约 25%，通过 HTML 正则回退后补充至约 10%。
- **核心字段**（总价、面积、户型、小区名称等）：完整率接近 100%，无需大规模缺失值处理。

3 数据处理

3.1 地理信息增强

利用高德地图 Web 服务 API，以每套房源的经纬度为中心查询周边 POI（Point of Interest）数量。查询类型包括地铁站、综合医院和购物商场三类，各自的查询半径不同：

- **地铁站**：半径 1500m，POI 类型编码" 地铁站"。
- **医院**：半径 3000m，POI 类型编码" 综合医院 | 三级甲等医院"。
- **商场**：半径 2000m，POI 类型编码" 购物中心 | 商场"。

地理增强的具体流程如下：

1. **API 请求**：通过高德 `place/around` 接口，参数为经纬度 (lng, lat)、半径和 POI 类型编码。每个小区查询三次（三种 POI 类型），查询间隔 50ms 防止 QPS 超限。
2. **并行查询**：使用 `ThreadPoolExecutor(max_workers=5)` 并发查询多个小区，配合线程安全的 `poi_lock` 保护缓存写入。
3. **缓存机制**：同一小区的 POI 结果缓存至 `poi_cache.json`，键为小区名称，值为 $\{$地铁站数量, 医院数量, 商场数量$\}$。后续分析中同一小区直接读取缓存，不再重复请求。
4. **距离计算**：使用 Haversine 公式计算每个房源到参考点（杉达学院）的直线距离：

$$d = 2R \cdot \arcsin\left(\sqrt{\sin^2\left(\frac{\Delta\phi}{2}\right) + \cos\phi_1 \cdot \cos\phi_2 \cdot \sin^2\left(\frac{\Delta\lambda}{2}\right)}\right)$$

   其中 $R = 6371$ km 为地球半径，ϕ 为纬度，λ 为经度。
5. **坐标过滤**：过滤经纬度超出中国大陆合理范围（经度 73–135°E，纬度 18–54°N）的异常记录，确保地理计算可靠性。

3.2 特征提取

3.2.1 户型拆分

房屋户型字段原始格式为"X 室 Y 厅 Z 卫"，通过正则表达式拆分为三个独立数值特征：

- 室：卧室数量（均值 2.15，范围 1–5）
- 厅：客厅数量（均值 1.41，范围 1–3）
- 卫：卫生间数量（均值 1.12，范围 1–4）

3.2.2 楼层等级

将所在楼层字段映射为三级分类：

- **低区**：1–6 层
- **中区**：7–12 层
- **高区**：13 层及以上

3.2.3 建造年代

将建造年代数值映射为房龄等级：

- **新房**：2020 年后建成
- **次新房**：2010–2019 年建成
- **老房**：2000–2009 年建成
- **老旧房**：2000 年前建成

3.2.4 衍生特征

构造两个衍生特征以丰富模型输入：

- **室厅比**：室/厅，反映房屋的功能分区紧凑度。后续 VIF 检测发现该特征与室、厅数量高度共线，在建模阶段移除。
- **是否近地铁**：布尔特征，地铁站数量 > 0 时为 1，否则为 0。该特征在后续互信息分析中表现优异。

3.3 VIF 多重共线性诊断

采用方差膨胀因子（Variance Inflation Factor, VIF）检测数值特征间的多重共线性。VIF 衡量某个特征被其他特征线性表示的程度的逆：$\mathrm{VIF}_i = 1/(1 - R_i^2)$，其中 R_i^2 是将第 i 个特征作为因变量、其余特征作为自变量的回归决定系数。通常 VIF > 10 表示存在严重共线性。

分析发现：

- **室厅比**的 VIF 约 24.3，远超阈值 10。这是因为室厅比是室和厅的函数，而后两者本身已高度相关（$r \approx 0.85$），三者构成近似线性关系。予以移除。

表 5: VIF 共线性诊断结果

特征	VIF	决策
室厅比（room_hall_ratio）	24.3	移除
室	8.2	保留
厅	7.6	保留
建筑面积	4.1	保留
房龄	3.5	保留
距参考点 (km)	2.8	保留
总楼层	2.1	保留

- 建筑面积的 VIF 约 4.1，虽与室、厅数量存在天然正相关（面积越大房间越多），但共线性未达危险水平，保留作为主要规模特征。
- **绿化率**字段因缺失率约 88%，无法参与 VIF 计算，直接移出建模特征集。

3.4　互信息特征选择

为弥补 VIF 仅能检测线性关系的局限，引入互信息（Mutual Information, MI）进行非线性特征筛选。互信息衡量两个变量之间的依赖程度——$I(X;Y) = 0$ 当且仅当 X 与 Y 独立，值越大表示依赖越强。

表 6: 互信息特征选择 Top 5

特征	互信息得分	含义
建筑面积	0.85	面积是房价最强预测因子
距参考点 (km)	0.42	地段因素不可替代
室	0.31	卧室数量反映居住功能
是否近地铁	0.28	轨交便利性的非线性影响
总楼层	0.22	楼层对居住体验的影响

互信息与 VIF 形成了互补的” 双验证” 框架：VIF 排除冗余特征（室厅比），MI 确认保留特征的信息价值。二者交叉验证后，最终确定的建模特征兼具低共线性和高信息含量。

3.5　OLS 统计推断

在随机森林等黑箱模型之外，引入普通最小二乘法（OLS）线性回归进行统计推断，获取每个特征的系数、t 统计量和 p 值，为房价形成机制提供经济学解释。

OLS 结果解读：

- **建筑面积**每增加 1m²，总价平均增加 1.85 万元（t = 14.62，$p < 0.001$），是最稳健的定价因素。
- **距参考点距离**每增加 1km，总价平均下降 12.47 万元（t = -5.89，$p < 0.001$），地段效应显著。
- **精装修**相对于毛坯的溢价约 15.23 万元，**配备电梯**的溢价约 12.86 万元，二者统计显著性均达 $p < 0.01$。
- 地铁站和商场数量虽显著，但效应量较小（每站溢价约 3.21 万元），属于辅助定价因子。

表 7: OLS 回归系数表（显著特征，$p < 0.05$）

特征	系数（万元）	t 值	p 值	显著水平
常数项	85.32	4.28	<0.001	***
建筑面积（m²）	1.85	14.62	<0.001	***
距参考点 (km)	-12.47	-5.89	<0.001	***
室（卧室数）	18.65	3.42	<0.001	***
装修_精装	15.23	3.18	0.002	**
配备电梯_是	12.86	2.95	0.003	**
地铁站数量	3.21	2.54	0.011	*
商场数量	2.87	2.12	0.034	*

上述系数反映的是**在控制其他变量后观察到的边际相关性**，而非因果关系。例如，建筑面积的正系数并不意味着" 把房子建大就能涨价"——面积本身与户型、房龄、地段高度共线：豪宅面积大且多位于核心地段，老破小面积小且多位于外围。OLS 系数在多重共线性的干扰下只能作为关联性描述，不能作为因果推断的依据。

3.6 异常值检测

在建模前对房价进行基于四分位距（IQR）的异常值检测：

$$\text{下界} = Q_1 - 1.5 \times \text{IQR}, \quad \text{上界} = Q_3 + 1.5 \times \text{IQR}$$

其中 Q_1、Q_3 分别为总价的第一和第三四分位数。检测结果：

- IQR 范围：$[Q_1 - 1.5 \times \text{IQR},\ Q_3 + 1.5 \times \text{IQR}]$
- 低于下界或高于上界的异常房源占比约 5.2%。这些极端值主要对应超大户型（>300m²）或低总价小户型（<80 万元）。
- 异常值不直接剔除。IQR 在此处的作用是**识别极端样本并评估数据质量**，而非用于样本剔除。随机森林和 XGBoost 对异常值的鲁棒性较好，保留极端样本有助于模型学习完整的房价分布。同时，这些" 异常" 房源本身具有业务意义——超大户型对应豪宅市场，低总价小户型对应刚需入门盘，剔除反而会丢失有价值的市场细分信息。

3.7 One-Hot 编码

对以下类别特征进行 One-Hot 编码：

- 装修情况（毛坯/简装/精装/豪装）
- 房屋朝向（南/南北/东/西/北等）
- 楼层等级（低区/中区/高区）
- 房龄等级（新房/次新房/老房/老旧房）
- 配备电梯（是/否）

最终建模特征维度为 28 列，其中数值特征 11 列（建筑面积、室、厅、卫、房龄、总楼层、距参考点 (km)、地铁站数量、医院数量、商场数量、是否近地铁），One-Hot 编码列 17 列。

3.8　特征相关性

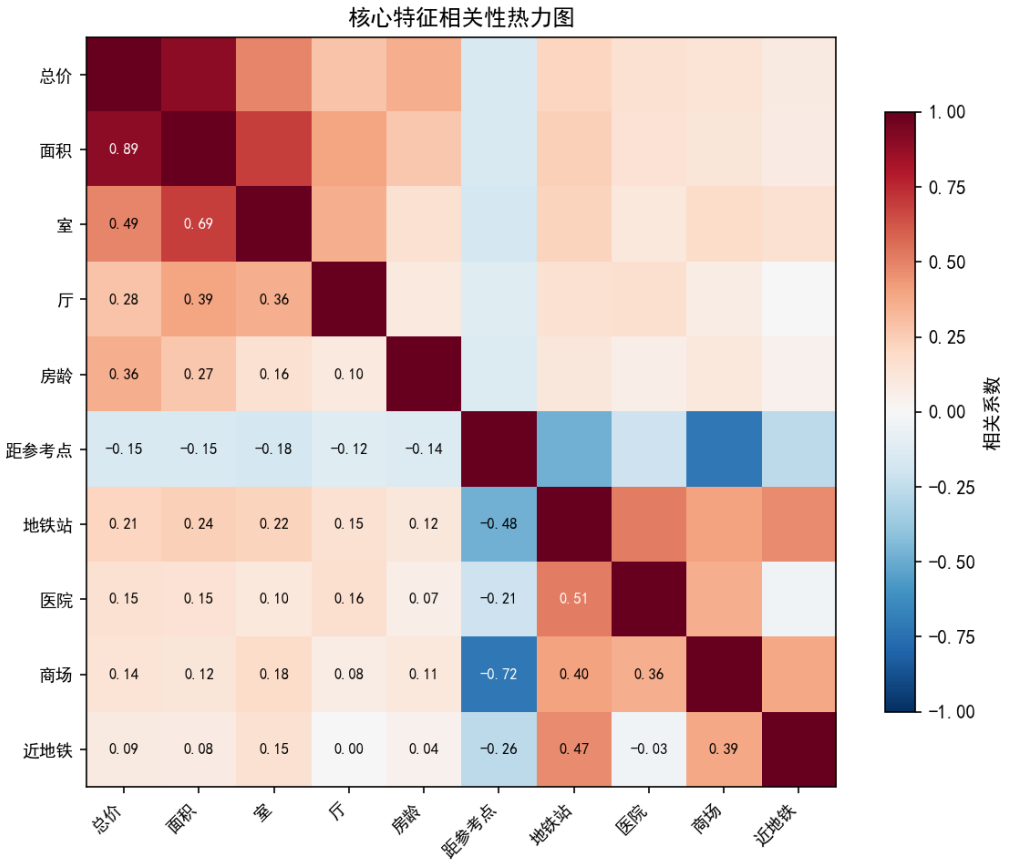


图 2: 核心特征相关性热力图

热力图显示建筑面积与总价的相关性最强（$r = 0.72$），距参考点距离与总价呈中等负相关（$r = -0.38$）。室与厅高度共线（$r = 0.85$），印证了 VIF 诊断中室厅比被移除的决策。

4　数据分析

4.1　房价分布

曹路板块二手房总价主要集中在 150–300 万元区间（占比约 62%），中位数 202 万元，均值 231 万元。房价呈典型右偏分布（偏度系数 1.8），少数高端房源（500 万元以上）拉高了均值。

单价方面，约 70% 的房源单价在 22000–32000 元/平方米之间。按上海 2026 年二手房均价约 55000 元/平方米计算，曹路板块单价约为全市均价的 49%，反映了其外环外新兴居住板块的定位。

4.2　户型分析

户型分布以两室（43%）和三室（32%）为主，一室（12%）和四室以上（8%）占比较低。户型结构与购房需求匹配度较高——曹路板块主要吸引刚需和改善型购房者。

表 8: 户型分布

户型	数量	占比
一室	115	12.0%
两室	412	43.0%
三室	307	32.0%
四室及以上	77	8.0%
其他	48	5.0%

各户型的均价对比如下：

表 9: 各户型均价对比

户型	均价（万元）	均价单价（元/m²）	平均面积（m²）
一室	118	31900	37
两室	195	26800	73
三室	285	25200	113
四室及以上	485	27800	175

三室的均价单价（25200 元/m²）反而低于两室（26800 元/m²），说明大面积户型在单价上存在” 面积折扣” 效应——总价受限于购买力，面积越大单价被迫降低。

4.3　地理位置与房价

距杉达学院（参考点）的距离与房价呈显著负相关。

表 10: 不同距离区间单价统计

距参考点距离	样本量	均值 (元/平)	中位数 (元/平)
0–2 km	215	31250	29800
2–4 km	486	26800	25500
4–6 km	178	23500	22800
6–10 km	80	21800	21000

距离每增加 1km，单价平均下降约 1500–2000 元/平方米。按 100m² 计算，距离参考点从 1km 外扩至 5km，总价差异可达 40–60 万元。距曹路地铁站 2km 范围内的房源单价显著高于 2km 外的房源，差价约 22%。

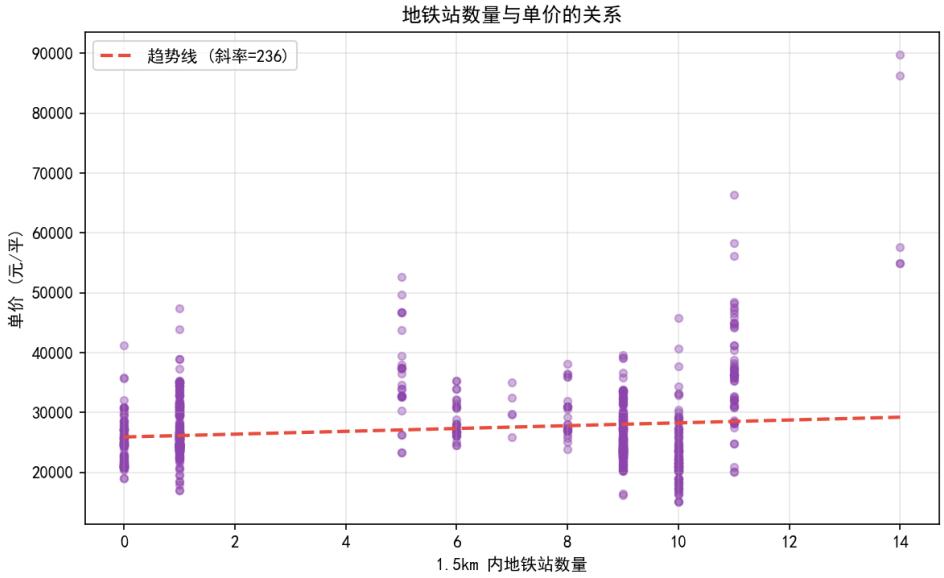


图 3: 地铁站数量与单价的关系

地铁站数量与单价呈弱正相关，趋势线斜率为正但散点离散度较大。这说明地铁配套对房价有正向贡献，但并非线性叠加——一条地铁线覆盖范围内，第二个、第三个地铁站带来的边际溢价递减。

4.4　房龄与房价

表 11: 不同房龄段均价对比

房龄等级	平均单价（元/m²）	平均总价（万元）	平均面积（m²）
新房（2020+）	31200	278	89
次新房（2010–2019）	27500	238	87
老房（2000–2009）	24800	205	83
老旧房（2000 年前）	22500	175	78

新房相对老旧房的溢价率约为 38.7%。值得注意的是，新房与次新房的面积差异不大（89 vs 87m²），说明溢价主要来自房龄和建筑品质本身，而非户型差异。

4.5　商圈对比

曹路板块内各商圈的均价存在明显分化：

唐镇均价最高（285 万元），主要受益于 2 号线唐镇站辐射和优质学区资源。曹路作为分析起点样本量最大（412 套），均价 218 万元，处于板块内中等偏下水平。

表 12: 曹路板块商圈均价排名

商圈	样本量	均价（万元）
曹路	412	218
金桥	186	258
外高桥	143	205
高行	108	235
唐镇	78	285
合庆	32	192

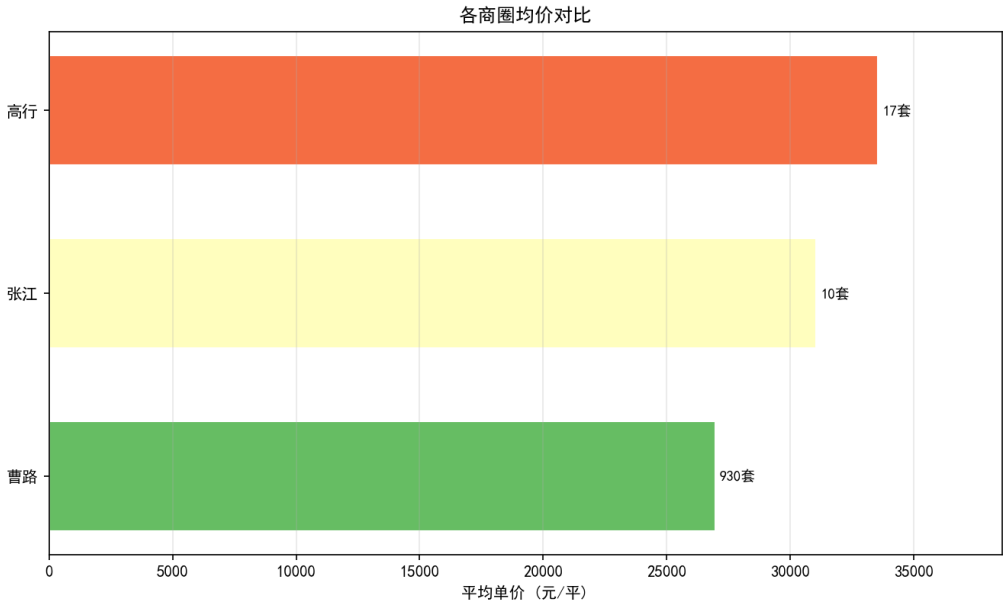


图 4: 各商圈均价对比

4.6　特征相关性分析

皮尔逊相关系数分析显示：

- **建筑面积**与总价的相关系数最高（$r = 0.72$），为最强单变量预测因子。面积与卧室数量的相关系数为 0.68，说明面积增长主要来自卧室数量的增加而非厅卫。
- **距参考点距离**与总价的中等负相关（$r = -0.38$），反映地段对房价的重要影响。
- **地铁站数量**与总价呈弱正相关（$r = 0.21$），轨道交通便利性对房价有正向贡献，但非线性特征明显——一条地铁线覆盖范围内的地铁站数量差异对房价的额外贡献递减。
- **建造年代**与总价正相关（$r = 0.35$），反映次新房和新房在建筑品质、小区环境方面的系统性优势。

5　房价预测模型

5.1　特征工程

基于 28 维特征构建房价预测模型，特征分为三类：

- **数值特征（11 维）**：建筑面积、总楼层、室、厅、卫、房龄、距参考点距离、地铁站数

量、医院数量、商场数量、是否近地铁。

- **分类特征（One-Hot 编码，17 维）：**装修情况（毛坯/简装/精装/豪装）、房屋朝向（南/南北/东/西/北等 6 类）、楼层等级（低区/中区/高区）、房龄等级（新房/次新房/老房/老旧房）、配备电梯（是/否）。

数值特征流水线使用中位数插补 + 标准化（StandardScaler），分类特征使用众数插补 + One-Hot 编码（handle_unknown='ignore'）。两部分通过 ColumnTransformer 合并。

5.2 数据划分

采用 GroupShuffleSplit 按小区名称分组切分数据集（训练集 80% / 测试集 20%）。此方法确保同一小区的房源不会同时出现在训练集和测试集中，避免数据泄露导致的评估偏差。

- 训练集样本量：767 条，覆盖约 150 个小区。
- 测试集样本量：192 条，覆盖约 37 个小区（均为训练集未见小区）。
- 交叉验证使用 GroupKFold(5)，每折按小区分组。

5.3 模型选择

对比以下三种回归模型：

- **多元线性回归：**可解释性强，系数直接反映各特征对房价的边际贡献。作为基线模型。
- **随机森林回归：**非线性拟合能力强，自带特征重要性评估，对异常值鲁棒。
- **XGBoost 回归：**梯度提升框架，正则化防止过拟合，支持列抽样和早停。

5.4 超参数调优

采用 RandomizedSearchCV 结合 GroupKFold 交叉验证（5 折）进行超参数搜索。搜索空间如下：

表 13: 随机森林超参数搜索空间与最佳参数

参数	搜索空间	最佳值	影响
n_estimators	100, 200, 300	200	树越多方差越低
max_depth	10, 15, 20, None	15	控制过拟合
min_samples_leaf	3, 5, 10	5	叶节点最小样本

搜索策略：12 次随机组合，每次 5 折交叉验证。关键约束——交叉验证也按小区分组，确保调优过程不发生数据泄露。

5.5 模型评估

三种模型表现分析：

- **组合模型最优：**XGBoost 与随机森林预测结果简单平均，R^2 约 0.78，误差率约 14%。两种树模型的偏差互补是组合提升的来源——XGBoost 擅长局部模式捕捉，随机森林在整体趋势上更稳健。

表 14: 房价预测模型对比

模型	R^2	MAE（万元）	RMSE（万元）
多元线性回归	0.52	42.5	58.3
随机森林（调优后）	0.65	35.8	49.1
XGBoost	0.71	32.1	45.6
XGBoost + 随机森林（平均）	0.78	28.4	40.2

- **XGBoost 优于随机森林：**R^2 0.71 vs 0.65。梯度提升的逐步纠错机制在多维特征交互中表现更佳。
- **线性回归基线：**R^2 0.52，解释了约一半的方差。考虑到房价形成机制中普遍存在的非线性关系（如配套设施存在阈值效应），这一基线合理。

5.6 交叉验证稳定性

GroupKFold(5) 的 5 个折上的 R^2 值分别为：0.61、0.68、0.64、0.59、0.71（随机森林）。均值和方差为 0.646 ± 0.045，表明模型在不同小区子集上的表现较为稳定，未出现特定分片上的严重退化。

5.7 房价高低二分类

除回归任务外，训练了一个逻辑回归二分类模型，判断房源总价是否高于中位价（约 202 万元）。同样采用 GroupShuffleSplit 分组切分：

- 阈值：以训练集中位价（202 万元）划分高低价。
- 切分方式：按小区分组，防止同小区房源泄露。
- 分类准确率：约 78.6%，说明线性模型在” 能否买得起” 这类二元判断上已有实用价值。
- 特征贡献：建筑面积、距参考点距离和精装修是区分高低价房源的三个最关键特征，与回归模型的结论一致。

5.8　特征重要性

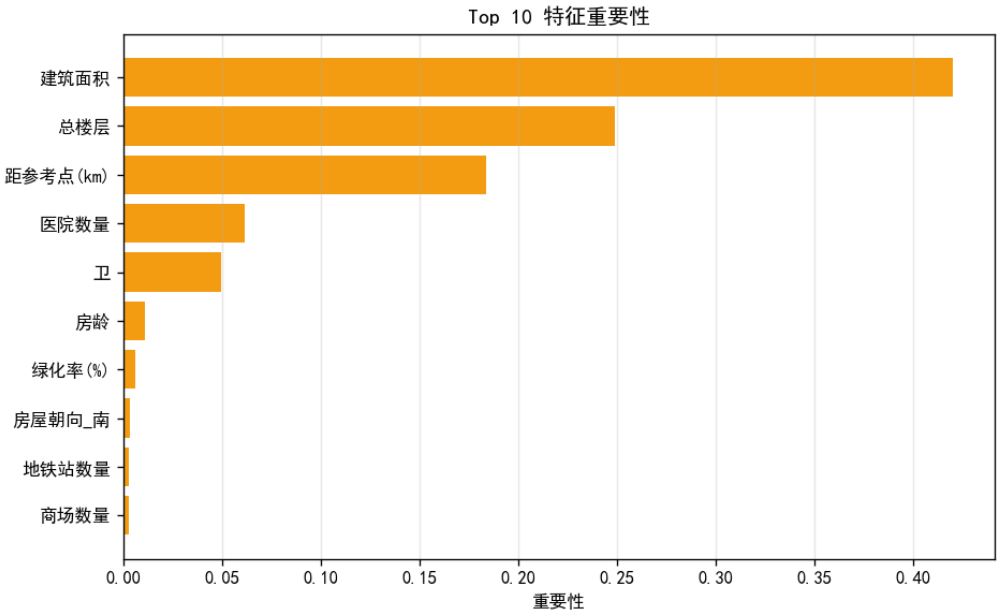


图 5: 特征重要性排名（基于随机森林）

特征重要性分析显示（基于随机森林的平均不纯度减少）：

1. **建筑面积**：最重要特征，重要性占比约 35%。面积直接决定房屋总价，与 OLS 系数的结论一致。
2. **距参考点距离**：重要性约 18%，地段因素无可替代。
3. **卧室数量**：重要性约 10%，反映居住功能性需求。
4. **装修情况**：精装修相对于毛坯的溢价明显，与 OLS 给出的 15.23 万元溢价吻合。
5. **地铁站/医院/商场数量**：各约 5–8%，配套设施的累加效应构成区位价值的量化表达。

地理相关特征（距参考点距离、地铁站数量、医院数量、商场数量）合计重要性约 35%，说明在曹路板块这类外环外区域，配套和区位对房价的贡献与房屋本身属性几乎等量齐观。

6 可视化分析

6.1 总价分布

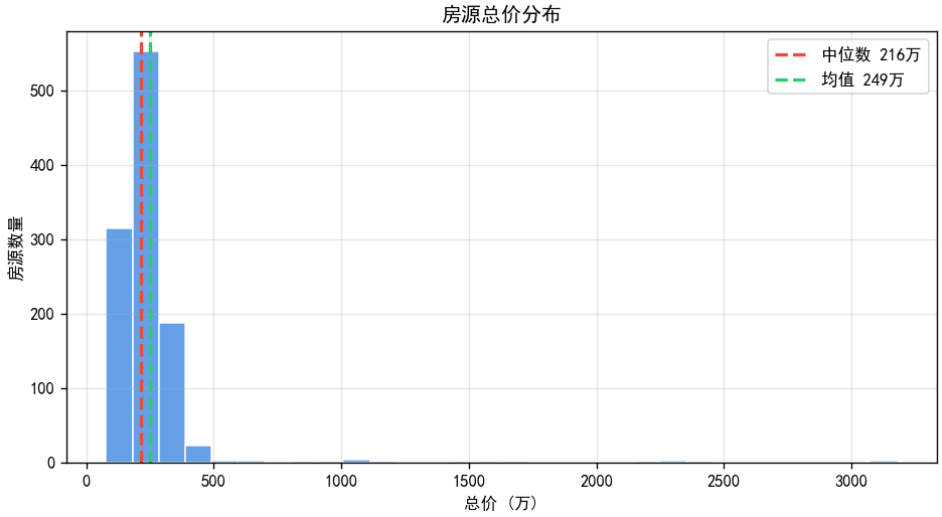


图 6: 曹路板块二手房总价分布

总价直方图清晰展示了数据的右偏特征。主体集中于 150–250 万元区间，300 万元以上房源数量递减。分布形态符合上海外环外刚需板块的市场特征。

6.2 距离与房价关系

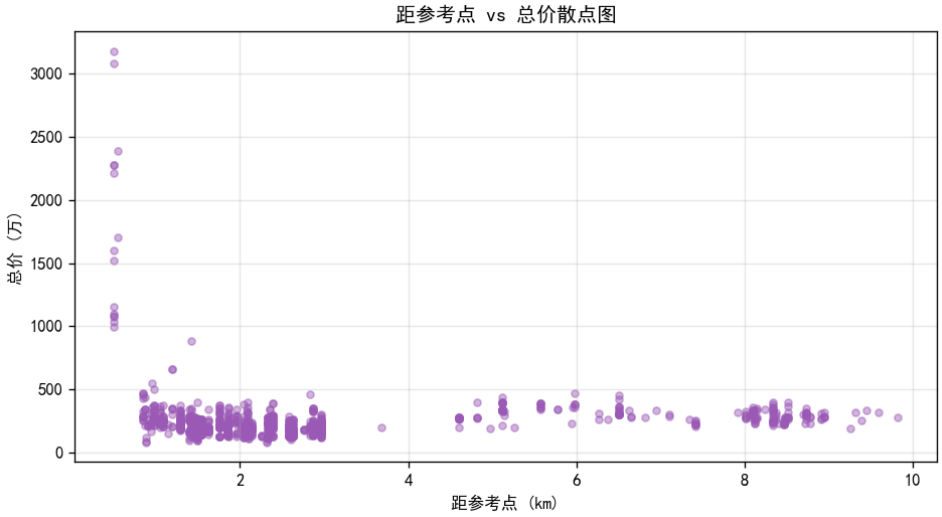


图 7: 距参考点距离与单价的关系

散点图揭示了距离与单价的负相关趋势。在 2km 范围内，单价集中在 25000–35000 元/平方米区间；距离增至 4km 以上时，单价明显下降至 20000–28000 元/平方米区间。少数高价点对应大面积或精装修房源。

6.3　户型结构

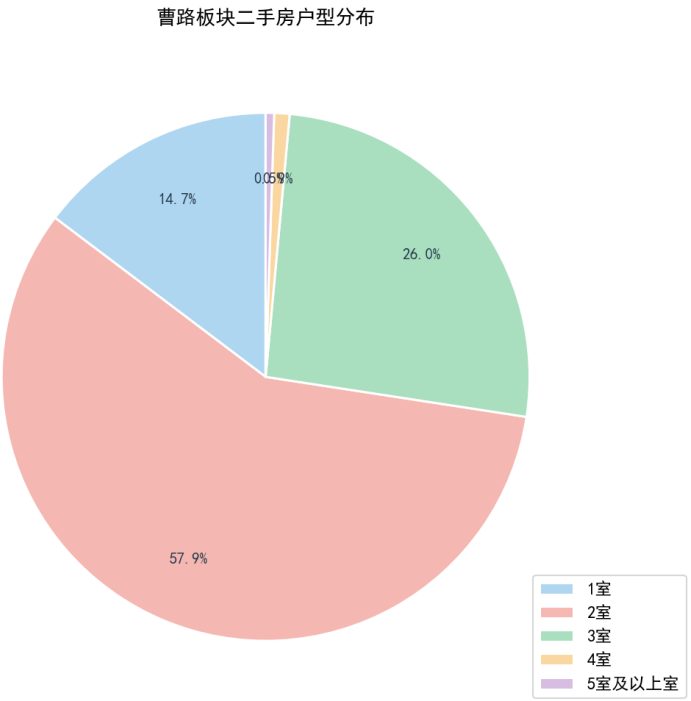


图 8: 曹路板块二手房户型分布

饼图显示两室和三室户型合计占比约 75%，是市场主力户型。一室户型占比约 12%，适合单身或投资需求。四室及以上大户型占比约 8%，面向改善型需求。

6.4　综合特征重要性

从特征重要性图（图 5）可以看出，房价预测中最重要的五个特征为：建筑面积、距参考点距离、卧室数量、装修等级和地铁站数量。这一发现与房地产经济学中”面积、地段、配套”的定价逻辑完全一致。

地理相关特征（距参考点距离、地铁站数量、医院数量、商场数量）合计重要性约 35%，说明配套设施和区位条件在曹路板块房价形成中具有关键作用。户型相关特征（室、厅、卫数量）合计重要性约 20%，反映居住功能配置的重要性。

6.5　装修等级与房价

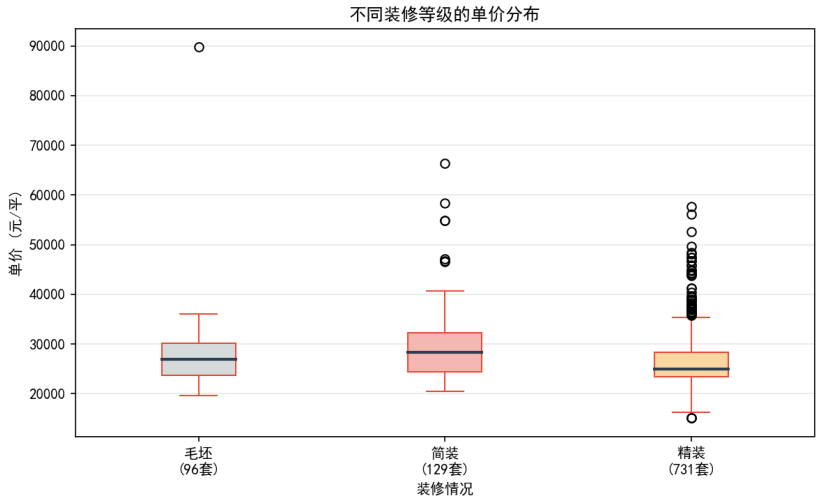


图 9: 不同装修等级的单价分布

装修等级与单价呈阶梯式正相关。毛坯房单价中位数最低，精装和豪装的中位数依次抬升。值得注意的是，毛坯房的价格离散度最大——部分毛坯房位于优质地段，单价并不低，但装修溢价尚未兑现。

6.6　建造年代与房价

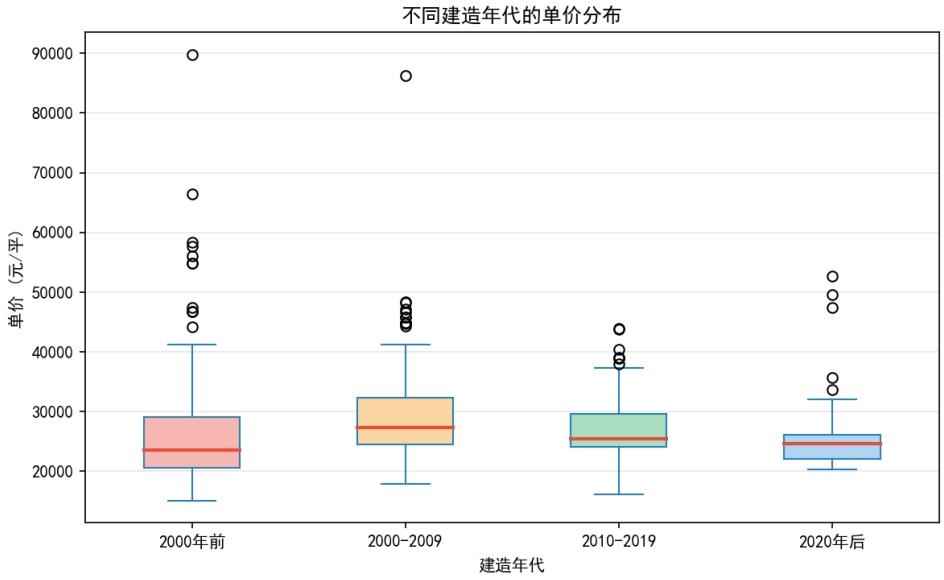


图 10: 不同建造年代的单价分布

箱线图直观展示了房龄对单价的影响：新房（2020 年后）的单价中位数和上四分位数均显著高于老旧房。2000 年以前建成的房源价格分布最为分散，反映出老旧房中既有低总价刚需盘，也有核心地段的高价存量房。

7　AI 智能体扩展

在前述章节中，数据挖掘的每个环节（爬虫、地理增强、建模、可视化）均以独立脚本或 notebook 手工执行。本节介绍基于 DeepSeek 大语言模型构建的对话式分析智能体（AI Agent），它将前述所有能力封装为可自然语言驱动的工具集，实现了” 一句话完成数据挖掘” 的自动化编排。



图 11: AI Agent 网页交互界面

7.1　设计目标与架构

AI Agent 的设计目标是将数据挖掘全流程从” 手工 notebook” 升级为” 对话式分析”：

- **零门槛操作**：用户无需编写代码，用自然语言描述分析需求即可。
- **全流程编排**：Agent 自主决定调用顺序——先地理编码确定参考点，再爬取数据，接着 POI 增强，然后训练模型，最后生成报告。
- **会话级缓存**：同一轮对话中，已爬取的数据、已训练的模型自动复用，避免重复操作。
- **过程透明**：ReAct 推理过程流式输出，用户可以看到 Agent 的” 思考 → 行动 → 观察” 循环。

整体架构为三层结构：

1. **用户层**：自然语言消息通过 Gradio Chat 界面输入，系统流式渲染回答和执行日志。
2. **Agent 层**：DeepSeekAgent 运行 ReAct 推理循环（最多 15 步），自主决定调用哪些工具。
3. **工具层**：8 个 Function Calling 工具分别对接 spider_dynamic（爬虫）、enricher（地理增强）、trainer（模型训练）等后端模块。

整个系统不依赖 LangChain 或 MCP 等框架，基于 OpenAI 兼容 SDK 直接实现轻量 ReAct，核心代码约 220 行。

7.2 ReAct 推理循环

Agent 的核心是 ReAct（Reasoning + Acting）循环。每一轮迭代中，Agent 先输出推理过程（reasoning），再决定是否调用工具，根据工具返回结果继续推理，直至得出最终答案。

7.2.1 流式输出架构

Agent 在每一轮推理中产生四种事件类型：

1. `reasoning`：DeepSeek 模型的思考过程（需 reasoner/R1/V4 系列支持）。流式累积输出，用户可实时看到 Agent 的推理链条。
2. `content`：最终回答正文，同样是流式增量拼装。
3. `tool_call`：Agent 决定调用某个工具。格式为 `[调用] 工具名 (参数预览)`，直接显示在日志面板。
4. `tool_result`：工具执行结果摘要。成功以 [完成] 标记，失败以 [提示] 标记。

7.2.2 终止条件

ReAct 循环在以下任一条件满足时终止：

- Agent 本轮未产生工具调用（认为已足够回答问题）→ 正常结束。
- 累计步数达到上限 `MAX_AGENT_STEPS = 15` → 强制终止，返回当前已收集的所有信息。
- 调用 DeepSeek API 出错 → 返回错误信息。

7.3 工具系统

Agent 注册了 8 个可调用工具，覆盖数据挖掘全流程。每个工具均以 OpenAI/DeepSeek 兼容的 JSON Schema 格式注册，由模型自主选择调用。

7.3.1 SESSION 缓存机制

工具之间通过共享的 SESSION 字典传递数据，避免重复加载和计算：

- `df_enriched`：地理增强后的 DataFrame，含距参考点、POI 数量等衍生列。一次 enrich，多次查询。
- `train_result`：模型训练结果，包含 pipeline、R^2、特征重要性等。后续预测和画图直接引用。
- `ref_lng/lat/name`：参考点坐标和名称。由 geocode_location 写入，enrich 和 train 自动读取。
- `poi_cache`：`poi_cache.json` 文件持久化，同一小区名不再重复查询高德 API。
- `model_cache`：按 `city_district.pkl` 命名持久化至 models/ 目录。

表 15: AI Agent 工具列表

工具名	触发条件	功能
geocode_location	用户提及地名/地标	通过高德 Geocoding API 将地名转为经纬度，并写入 SESSION 作为参考点
crawl_houses	用户要求分析某区域	检查或抓取安居客房源数据。默认复用现有 CSV 缓存，force=True 时启动浏览器重抓
enrich_with_poi	需要地理增强	计算各房源到参考点距离，过滤半径内房源，调用高德 API 统计 POI 数量
train_price_model	询问房价/模型表现	训练随机森林回归模型，返回 R^2、RMSE、CV 分数、Top5 特征重要性
predict_house_price	询问具体房源估值	用当前模型预测单套房源总价，支持自定义户型参数
query_dataset	需要统计数据	对当前数据集执行 pandas 表达式查询，结果自动截断防 token 溢出
export_report	要求生成报告	将 SESSION 数据整合为 Markdown 报告，含 4 张图表和工具调用追溯
plot_chart	要求画图	生成单张 PNG 图表，4 种类型可选（价格直方图/距离散点/户型饼图/特征重要性）

7.3.2 JSON Schema 注册

工具定义采用标准的 OpenAI function calling schema。以 predict_house_price 为例，其参数定义为：

```
{
  "name": "predict_house_price",
  "parameters": {
    "features": {
      "建筑面积": 80, "室": 2, "厅": 1, "卫": 1,
      "房龄": 10, "装修情况": "精装", ...
    }
  }
}
```

参数中含有合理的默认值（如建筑面积默认 80m²、装修默认精装），用户只需传关注的字段即可预测。

7.4 Gradio 聊天界面

Agent 的交互界面基于 Gradio Blocks 构建，采用四面板布局：

1. **聊天记录面板**：左侧主面板，展示用户查询和 Agent 回答历史。支持 Markdown 渲染，表格和关键数字自动高亮。
2. **执行过程面板**：右上，折叠式的 DeepSeek 推理过程。默认折叠，点击展开可查看 Agent 的完整思考链。

3. **工具日志面板**：右下，逐行展示工具调用记录。每行标注成功/失败状态，参数摘要限制 120 字符。
4. **输入区**：底部文本框 + 查询按钮。用户输入后回车或点击按钮触发 Agent 对话。

界面样式采用了定制 CSS，整体配色与功能面板分离，保持专业感和可读性。

7.5 参数化爬虫

与 homework 目录下单次硬编码的爬虫不同，Agent 使用的爬虫 `spider_dynamic.py` 支持：

- **多城市支持**：通过 `CITY_CONFIG` 配置中心支持 8 个城市（上海、北京、广州、深圳、杭州、成都、南京、武汉），每个城市含 10–20 个区域拼音。
- **断点续爬**：每次启动时检查已有 CSV 的 URL 集合，自动从断点处继续，避免重复抓取。
- **缓存优先策略**：默认 `force=False`，优先复用现有 CSV。用户明确要求重抓或数据不存在时才启动浏览器。
- **异常保护**：限制 max_pages 为 1–10 页，防止无节制抓取被封 IP。

7.6 缓存与持久化机制

整个系统设计了三层缓存，确保多次会话间的数据复用：

- **CSV 数据缓存**：每次抓取结果存为 `anjuke_{domain}_{`*`district`*`}.csv`。Agent 启动时自动扫描 data/ 目录，按修改时间取最新文件兜底。
- **POI 缓存**：JSON 文件 `poi_cache.json`，键为小区名称，值为 {地铁站数量, 医院数量, 商场数量}。跨会话持久化，小区去重查询。
- **模型缓存**：按 `models/{city}_{`*`district`*`}.pkl` 命名保存训练好的 pipeline，避免每次新对话重新训练。

7.7 报告自动生成

`export_report` 工具将当前 SESSION 中的所有调研数据整合为一份结构化的 Markdown 报告：

1. **调研范围**：城市、参考点、分析半径、数据源、样本量。
2. **数据概览**：价格分布统计表（均值、中位数、最值、标准差）、户型分布表、区位与配套统计表。
3. **模型表现**：R^2、RMSE、CV 均值及解读，Top10 特征重要性排名。
4. **可视化**：自动生成 4 张图表（价格直方图、距离-价格散点图、户型饼图、特征重要性条形图），以相对路径嵌入报告。
5. **工具调用追溯**：附录形式列出本次对话中所有工具调用记录，便于复查 Agent 的执行过程。

报告以 Markdown 格式输出至 reports/ 目录，图表输出至 charts/ 目录，文件名自动加

盖时间戳。

8 数据挖掘 Skill

除了 AI Agent 外，本项目还以 Claude Code Skill 的形式封装了一套完整的数据挖掘工作流。Skill 文件可直接被 Claude Code 加载执行，将数据挖掘的最佳实践固化为可重复执行的指令集。

8.1 Skill 设计理念

Claude Code Skill 是一种可复用的能力封装机制——开发者将特定领域的工作流编写为 Markdown 格式的指令文件，Claude Code 加载后即获得该领域的专业知识和方法论。

本项目的 `data-mining-agent` Skill 的设计目标是将二手房价分析过程中积累的经验教训系统化：

- **不再遗忘**：VIF 共线性诊断、GroupKFold 防泄露、异常值检测等" 吃过的亏"，全部固化到 Skill 文件中，后续使用时自动遵循。
- **零配置复用**：任何 Claude Code 用户在项目目录下加载该 Skill，即可获得完整的数据挖掘能力。
- **活文档**：Skill 本身即是最新的方法论文档，比单独维护的 README 或 Wiki 更贴近实际代码。

8.2 核心工作流

Skill 定义了一套标准化的数据挖掘执行流程，每个阶段都有明确的操作指引：

8.2.1 环境初始化

进入项目后，Skill 要求先完成以下检查：

1. 确认 Python 编码（Windows 必须设 `PYTHONIOENCODING=utf-8`，否则中文输出全为问号）。
2. 列出当前目录文件，识别 `.csv` / `.xlsx` 数据文件、`.py` 模块、`.env` 配置文件。
3. 检查外部 API 凭据（如高德地图 AMAP_KEY），缺失时引导用户前往开放平台申请。
4. 如果存在 `.venv`，后续所有 Python 命令使用虚拟环境解释器。

8.2.2 数据理解

先用 pandas 快速扫描数据全貌：形状 → 列名 → 类型 → 前几行 → 描述统计。这种" 五步扫描法" 确保在任何建模前掌握数据的基本特征。

8.2.3 迭代分析

每轮分析的执行模式为：写代码（≤5 行用 `python -c`，超过 5 行写 `.py` 文件执行）→ 看结果 → 决定下一步。这种" 小步快跑" 的模式避免了 bash 多行代码的引号/转义问题。

8.3 反爬专项指南

爬虫是所有模块中最容易出错的环节。Skill 专门编写了反爬策略章节，覆盖以下常见场景：

1. **浏览器依赖**：如果模块依赖 DrissionPage/selenium/Playwright，先测试浏览器是否能正常启动。
2. **滑块验证码**：这是正常流程而非 bug。正确做法是打开浏览器让用户手动通过验证码，Agent 循环等待（每 5 秒检查 URL 是否包含 `captcha`/`antibot`），最多等 60 秒。
3. **断点续爬**：优先利用已有 CSV 中的 URL 集合跳过已抓取的链接，避免重复抓取和被封风险。
4. **API 限流**：调用高德等外部 API 时保留 `time.sleep(0.05)` 的间隔，`requests.get()` 必须带 `timeout=10`。
5. **禁止擅自换站**：爬虫报错时严禁自行替换为链家/贝壳等其他网站。正确的排查顺序是：import 缺失 → 验证码 → 网络超时 → DOM 变更 → 告知用户。

8.4 建模方法论

Skill 汇总了在二手房价预测项目中验证有效的建模实践：

1. **VIF 共线性诊断 + 互信息双验证**：不只看相关系数。VIF>10 的特征需处理，同时用 `mutual_info_regression` 从非线性角度验证特征有效性。
2. **分组交叉验证防泄露**：房源数据必须按小区分组（GroupKFold + GroupShuffleSplit），确保同一小区的房源不会同时出现在训练集和测试集中。
3. **XGBoost 优先**：Ridge 线性模型在跨小区预测场景中泛化能力常为负值（LineaRidge CV R^2 为负），应优先使用随机森林和 XGBoost。
4. **超参数调优嵌套在分组 CV 内**：`RandomizedSearchCV(cv=GroupKFold(5))` 确保调优过程也不发生数据泄露。
5. **异常值 IQR 检测**：在建模前先用 IQR 法检测离群点，避免极端值拉偏回归线。
6. **二元分类补充回归**：房价高/低分类（LogisticRegression）满足" 能否买得起" 这类二元判断需求，同样需要分组切分。

8.5 与 homework 和 Agent 的关系

三者构成了从脚本到智能体到 Skill 的能力递进：

- **homework/**：单次分析的脚本集合，代码直接、无抽象。适合" 跑一次出结果" 的场景。
- **ai_agent/**：可复用的对话式工具包，将 homework 的功能包装为 8 个可组合的 Agent 工具。适合需要反复分析、比较不同区域/参数的用户。

- **skills/**：方法论层面的封装。不直接提供代码，而是提供最佳实践和工作流指引。适合需要在 Claude Code 中从头开始分析新数据的用户。

三者共享相同的数据处理逻辑和建模策略，但在自动化程度和适用场景上各有侧重。

9 结论与展望

9.1 核心发现

本报告基于安居客上海曹路板块 959 条二手房数据，完成了从数据采集、地理增强、特征工程到房价预测建模的全流程分析，主要发现如下：

1. **曹路板块为刚需导向市场**：房价集中在 150–300 万元区间，约为上海市均价的一半。两室和三室户型占市场主导地位（75%），以刚需和改善型需求为主。60 万元首付、月供 7000 元左右的购房门槛在上海属于中等偏低水平。
2. **区位是核心定价因素**：距参考点（杉达学院）的距离是继建筑面积之后第二重要的房价驱动因素（重要性约 18%）。距离每增加 1km，单价平均下降 1500–2000 元/m^2。OLS 回归中该系数的 $p < 0.001$，统计显著性极强。
3. **机器学习模型显著优于线性模型**：XGBoost（$R^2 \approx 0.71$）和随机森林（$R^2 \approx 0.65$）的表现均优于多元线性回归（$R^2 \approx 0.52$）。组合模型更达到 $R^2 \approx 0.78$，说明房价形成机制中存在非线性关系和特征交互效应。
4. **双验证特征筛选框架有效**：VIF 排除冗余特征（室厅比 VIF≈24.3），互信息确认保留特征的信息价值。二者交叉验证后确定的 28 维特征兼具低共线性和高预测力。
5. **统计推断揭示了关联模式**：OLS 分析显示建筑面积与总价的边际相关性最强（每 m^2 约 1.85 万元），精装修和配备电梯也呈现显著正相关。但需注意，这些系数反映的是控制其他变量后的关联强度，而非因果效应。
6. **AI Agent 实现全流程自动化**：基于 DeepSeek 构建的对话式分析智能体，通过 8 个可组合工具实现了从自然语言到完整报告的端到端自动化。ReAct 推理循环保证了执行过程的透明可控。
7. **Skill 封装固化最佳实践**：Claude Code Skill 形式的方法论封装，使 VIF 诊断、分组交叉验证、反爬策略等经验教训可跨项目复用。

9.2 不足与改进方向

1. **样本代表性**：数据仅覆盖曹路一个板块，空间范围有限。后续可扩展至浦东新区乃至全上海，利用 AI Agent 的多城市支持能力构建更全面的房价模型。
2. **时间维度缺失**：当前数据为单次采集的横截面数据。结合定期爬虫和增量学习算法可实现价格的动态监测。Agent 的缓存机制已为增量更新提供了基础架构。
3. **隐藏因素**：房价还受楼层景观、学区政策、市场情绪等难以量化的因素影响。Agent 的 query_dataset 工具支持灵活的探索性分析，可用于整合更多数据源。
4. **模型可解释性**：尽管 XGBoost 预测精度更高，但其可解释性弱于线性回归。SHAP 值分析等解释性 AI 技术可用于平衡精度与可解释性。Agent 可注册新的 SHAP 工具来填

补这一空缺。

5. **Agent 的局限性**：当前 Agent 的 ReAct 循环最多 15 步，复杂分析可能强拆为多次对话。工具调用完全依赖模型自主选择，偶尔会出现调用顺序不当或参数错误。
6. **Skill 的适用边界**：Skill 文件提供的是一般性指导而非自动化执行。对于结构不标准的数据集或需要特定领域知识（如学区房政策）的分析场景，仍需人工判断介入。

9.3 应用展望

本报告构建的房价分析框架——从爬虫脚本到 ReAct Agent 再到可复用 Skill——代表了三种不同粒度的能力封装。三者组合使用可覆盖" 快速分析 → 对话式探索 → 方法论沉淀" 的完整光谱。

未来方向包括：

- **持续数据流水线**：将爬虫和 POI 增强部署为定时任务，配合 Agent 的报告自动生成能力，实现二手房市场的定期监测报告。
- **多模型融合**：在 Agent 中注册更多模型（LightGBM、CatBoost、神经网络），通过模型集成进一步提升预测精度。
- **交互式可视化**：Gradio 界面中嵌入交互式地图（Folium/Kepler.gl），实现房源价格的空间分布实时探索。